

Unix & Shell-Programmierung SS21

Vorlesungswoche 7

Helga Karafiat

FH Wedel

Befehl	Beschreibung
<code>cat</code>	Text ausgeben, neutrales Element bzgl.
<code>cut</code>	Spalten selektieren und ausschneiden
<code>sort</code>	Daten zeilenweise sortieren
<code>uniq</code>	doppelte aufeinanderfolgende Zeilen löschen
<code>wc</code>	Zeichen, Wörter und Zeilen zählen
<code>tr</code>	Zeichen übersetzen bzw Zeichen löschen
<code>grep</code>	Zeichenstrom zeilenweise filtern
<code>sed</code>	Textmanipulation auf Zeichenströmen
<code>awk</code>	Programmiersprache zum Manipulieren von Texten (Pattern Matching Language)
<code>sh</code>	und viele andere (z.B. <code>bash</code> , <code>csh</code> , <code>perl</code> , <code>tcl</code> , <code>ruby</code>): Sprachen zum Erstellen von eigenen komplexen Filtern

- `grep`

- ▶ `global\regularexpression\print` bzw.
global search for a regular expression and print out matched lines
- ▶ sucht Textzeilen anhand eines angegebenen Musters heraus
- ▶ verschiedene Varianten
 - ★ `grep -E` (oder `egrep`): Verarbeitung von erweiterten regulären Ausdrücken
 - ★ `grep -F` (oder `fgrep`): Auswertung Ausdrücke als feste Zeichenketten (statt regulärer Ausdruck)

- `sed`

- ▶ stream editor
- ▶ Erlaubt die Manipulation von Zeichenketten in Zeichenströmen
- ▶ arbeitet zeilenweise
- ▶ hauptsächliche Verwendung: Suchen und Ersetzen
- ▶ `sed -E` um erweiterte reguläre Ausdrücke zu verwenden

- Vorsicht GNU (Linux) und BSD (MacOS) verhalten sich was reguläre Ausdrücke angeht teilweise sehr unterschiedlich und auch abweichend zu POSIX!

- Aufgaben: Suchen nach Textmustern (Filtern) oder Suchen und Ersetzen von Textmustern
- Reguläre Ausdrücke (vereinfacht ausgedrückt): Beschreibungssprache für Textmuster
- Motivation:
 - ▶ Automatisierung von wiederkehrenden Aufgaben
 - ▶ Vermeidung von “Äffchenarbeit”, wie
“Erstelle eine Liste aller Überschriften aus diesen 100 html-Dateien.”
oder “Ersetze alle Vorkommen von ‘foo’ durch ‘bar’.”
- Einfachstes Beispiel für einen regulären Ausdruck schon bekannt:
`grep TODO`
 - ▶ sucht alle Zeilen in denen die Zeichenkette “TODO” enthalten ist
(genaugenommen: Ein T gefolgt von einem O gefolgt von einem D gefolgt von einem O).
 - ▶ einfachster regulärer Ausdruck ist also eine Zeichenkette
- Unterscheidung laut POSIX in
Basic Regular Expressions (BRE) und Extended Regular Expressions (ERE)

- `grep [OPTIONS]... PATTERN [FILE]...`
- Wichtige Optionen
 - ▶ `-i` ignoriert Groß-/Kleinschreibung
 - ▶ `-v` gibt alle Zeilen aus, die nicht matchen
 - ▶ `-q` stiller Modus: `grep` gibt keine Matches aus, sondern setzt lediglich Exitcode entsprechend
 - ▶ `-s` unterdrückt Fehlermeldungen (häufig zusammen mit `-q`)
 - ▶ `-e PATTERN` notwendig zur Angabe mehrerer Patterns
 - ▶ `-C ZAHL` Kontext: gibt `ZAHL` Zeilen um den Match aus (`-A` für nur dahinter, `-B` für nur davor)
 - ▶ `-n` gibt die Zeilennummern mit aus
- Beispiel: Alle Zeilen mit Vorkommen der Zeichenkette `foo` in der Datei `foo.txt` finden
`cat foo.txt | grep 'foo'`
- Tipp: Reguläre Ausdrücke am Besten immer in Quotes schreiben
(je nach gewünschtem Effekt `weak` oder `strong`)

- `sed [OPTION]... 'COMMAND' [FILE]...`
- **COMMAND: s/SUCHWORT/ERSETZUNG/FLAG**
 - ▶ `s` am Anfang steht für substitute, also Ersetzen (andere Zeichen nur für komplexere Skripte vonnöten)
 - ▶ **SUCHWORT**: gesuchter Ausdruck
 - ▶ **ERSETZUNG**: das wodurch ersetzt werden soll
 - ▶ **FLAG**: steuert Verhalten von `sed`
 - ★ `i`: case insensitive
 - ★ `g`: global, ersetzt also nicht nur das erste Vorkommen in der Zeile, sondern alle Vorkommen
 - ★ **ZAHL**: Ersetzt das ZAHLte Vorkommen in einer Zeile
 - ★ `p`: wenn `-n` aktiv ist, modifizierte Zeile ausgeben
 - ▶ `/`: Trennzeichen
 - ★ `/` wird klassisch als Trennzeichen verwendet, kann aber auch jedes andere Zeichen sein (das Zeichen wird dadurch definiert, dass es nach dem `s` steht)
 - ★ häufige Trennzeichen: `,`, `;`, `|`, ...

- POSIX-konforme Optionen
 - ▶ `-e COMMAND` zur Angabe von mehreren Ausdrücken
 - ▶ `-f COMMAND_FILE` zur Angabe von Ausdrücken über eine Skript-Datei
 - ▶ `-n` Unterdrücke die Ausgabe der modifizierten Zeilen, stattdessen Ausgabe explizit durch `p`
- GNU `sed` verfügt über Vielzahl an Erweiterungen und Optionen (siehe `man sed`),
`--posix` schaltet GNU-Erweiterungen aus (Vorsicht: Option nicht POSIX-konform)
- Beispiele:
 - ▶ Alle Vorkommen der Zeichenkette *foo* aus *foo.txt* durch *bar* ersetzen
`cat foo.txt | sed 's/foo/bar/g'`
 - ▶ Als Ersetzung kann auch nichts angegeben werden, das entspricht dann löschen,
z.B. `sed 's/nichts/'`
- Vorsicht: Da `sed` zeilenbasiert arbeitet, können Zeilenumbrüche nicht ohne weiteres gelöscht werden, dafür bietet sich dann `tr` an

- vi hat gleiche Funktionalität für reguläre Ausdrücke wie grep & sed
- Suchen im Befehlsmodus mit / auch mit regulären Ausdrücken möglich z.B. /foo
- Im Befehlsmodus kann mit :%s ein Ersetzungsbefehl eingeleitet werden z.B. :%s/foo/bar/g (% steht für ganze Datei)
- Im visual-Mode kann Suchen und Ersetzen auch auf der Auswahl durchgeführt werden
 - ▶ Wechseln in den visual-Mode mit v oder V (visual line)
 - ▶ Markieren mit den Richtungstasten (h, j, k, l)
 - ▶ Eintippen von : führt dazu, dass die Zeilenangabe '<', '>' eingesetzt wird (ersetzt das %)
 - ▶ danach s eingeben leitet den Ersetzungsbefehl ein
 - ▶ Beispiel: : '<', '>'s/foo/bar/g
- Nettes vim-Feature: Wenn der Suchteil des Ausdrucks leer gelassen wird, nimmt vim den letzten Ausdruck nach dem mit / gesucht wurde

- Reguläre Ausdrücke sind zeichenweise aufgebaut und werden auch Zeichen für Zeichen von links nach rechts ausgewertet
- jedes Zeichen hat eine eindeutig definierte Bedeutung
- Reguläre Ausdrücke bestehen aus
 - ▶ Literalen (“normalen” Zeichen) und
 - ▶ Metazeichen (Zeichen mit einer besonderen Bedeutung)
- Einfachster regulärer Ausdruck: Zeichenkette aus Literalen (Wort)
- Besonderes Metazeichen: Backslash (`\`)
 - ▶ wird verwendet um
 - ★ manche Metazeichen einzuleiten oder
 - ★ andere Metazeichen zu maskieren, so dass sie als “normales” Zeichen gelesen werden
 - ▶ ist selbst immer ein Metazeichen, kann aber mit sich selbst maskiert werden (`\\`)

Wie “matchen” reguläre Ausdrücke?



- Dass ein regulärer Ausdruck “matcht” bedeutet, dass er auf einen Teil des Textes (oder den ganzen Text) passt
- Beispiele

```
echo "Hallo Welt" | grep 'Hallo'  
      ^^^^^
```

```
echo "Hallo Welt" | grep ' Welt'  
      ^^^^^
```

```
echo "Hallo Welt" | grep 'H'  
      ^
```

```
echo "Hallo Hallo Welt" | grep 'H'  
      ^      ^
```

- Zeilenanker sind:
 - ▶ Zeilenanfang, Schreibweise: ^
 - ▶ Zeilenende, Schreibweise: \$
- Beispiele

```
echo "Hallo Welt" | grep '^Hallo'
      ^^^^^
```

```
echo "Hallo Hallo Welt" | grep '^Hallo'
      ^^^^^
```

```
echo "Hallo Welt" | grep ' Welt$'
      ^^^^^
```

```
echo "Hallo Welt" | grep '^Hallo Welt$'
      ^^^^^^^^^^^
```

- Schreibweise [...]
- Bedeutung: beschreiben eine gültige Eingabemenge für ein Zeichen
- Beispiel

```
echo "Hallo Hello Hullo" | grep 'H[ae]llo'  
      ^^^^^^  ^^^^^^
```

matcht nur auf *Hallo* oder *Hello*, aber sonst nichts!

- Weiteres Beispiel nur Vokale: [aeiou]
- Intervallschreibweise möglich z.B. [a-z], [A-Z] oder [0-9]
- Beliebige kombinierte Schreibweise möglich, z.B. [a-zA-Z0-9_] (Buchstabe, Zahl oder Unterstrich)

- Negation möglich

- ▶ Syntax: `[^...]`
- ▶ Beispiel `[^xyz]` alle Zeichen außer x, y und z
- ▶ Vorsicht `[^x]` (jedes Zeichen außer x) erwartet ein Zeichen und matcht nicht auf leer
Beispiel: `echo "Hausbau" | grep 'au[^s]'`

- Andere Metazeichen verlieren innerhalb von `[]` ihre Bedeutung

- ▶ kein Quoting notwendig,
z.B. `[.ab$]` erlaubt das Zeichen: ., a, b oder \$
- ▶ Sonderfälle: `-`, `]` und `^`
 - ★ wenn nach `^` gesucht wird, darf es nicht nach der öffnenden eckigen Klammer stehen
 - ★ wenn nach `-` gesucht wird, muss es entweder nach der öffnenden oder vor der schließenden eckigen Klammer stehen
 - ★ wenn nach `]` gesucht wird, muss es nach der öffnenden eckigen Klammer stehen

- Beispiel (Matche Großbuchstaben, `[`, `]`, `-`, `^`):

```
echo "Hallo [Name] - wie geht es Dir ^^?" | grep '[][^\A-Z-]'
```

\wedge $\wedge\wedge$ \wedge \wedge \wedge $\wedge\wedge$

- Schreibweise: `.`
- Bedeutung: beschreibt genau ein beliebiges Zeichen
- Beispiele

- ▶ *Hallo, Hello* u.s.w.

```
echo "Hallo Hello Hullo H llo HElllo Hllo" | grep 'H.llo'  
      ^^^^^ ^^^^^ ^^^^^ ^^^^^ ^^^^^
```

- ▶ Flexible Datumsangabe:

```
[0-3] [0-9] . [0-3] [0-9] . [0-9] [0-9] [0-9] [0-9]
```

matcht auf: 14.06.2020, 06/14/2020, 14-06-2020

aber auch auf: 0123456789

- Schreibweise: *
- Bedeutung: Zeichen davor kann vorkommen, also 0 mal bis beliebig oft
- Beispiele

```
echo "Hallo      Welt" | grep 'Hallo *Welt'
      ~~~~~
```

```
echo "HalloWelt" | grep 'Hallo *Welt'
      ~~~~~
```

- kann auf jedes einzelne Zeichen angewendet werden, z.B. auch auf [...]
- Beispiel beliebig lange positive Ganzzahl: [0-9]*
 - ▶ Vorsicht: Erlaubt auch leere Zeichenketten oder solche ohne Zahlen
 - ▶ Abhilfe: [0-9][0-9]* (mindestens eine Zahl muss vorhanden sein)

- Häufige Kombination `.*` (beliebiges Zeichen, beliebig oft)

- ▶ Vorsicht: Reguläre Ausdrücke sind meistens “greedy” bzw arbeiten nach dem “longest match” Prinzip, d.h. es wird so viel gematcht, wie irgendwie geht
- ▶ Beispiel

```
echo "<tag1>Text</tag1>" | grep '<.*>'
      ^^^^^^^^^^^^^^^^^
```

- Vorsicht: `*` in regulären Ausdrücken ist nicht vergleichbar mit `*` aus den Datei-Wildcards
 - ▶ regulärer Ausdruck: Bezug immer auf das davor stehende Zeichen
 - ▶ Wildcard: Bezug zu im Dateisystem vorhandenen Dateien

- Schreibweise: `\{n,m\}`
- Bedeutung: das Zeichen davor muss mindestens `n` und höchstens `m` mal vorkommen
- Variationen:
 - ▶ `\{n\}`: Das Zeichen kommt genau `n` mal vor
 - ▶ `\{n,\}`: Das Zeichen kommt mindestens `n` mal vor
- Einfaches Beispiel:

```
echo "Hallo" | grep '1\{3,\}'
```

matcht nicht, weil nur zwei aufeinanderfolgende 1 enthalten sind und nicht mindestens drei

- Weitere Beispiele

```
echo "aaabbc aabc a aaaab aaaaa" | grep 'a\{2,3\}'
      ^^^      ^^      ^^^      ^^^^^
```

```
echo "aaabbc aabc gnargl aaaab" | grep 'a\{2\}'
      ^^      ^^      ^^^^
```

```
echo "aaabbc aabc gnargl aaaab" | grep 'a\{3,\}'
      ^^^      ^^^^
```

```
echo "aaab ab aabc aaaaac" | sed 's/a\{2,3\}/b/g'
```

- Schreibweise: `\(...\)` und `\1` bis `\9`
- Bedeutung:
“Filtere das was auch immer ein bestimmter früherer Teil des Ausdrucks gefiltert hat”
- Vorgehen in zwei Stufen
 - ▶ Bis zu neun Unterausdrücke können in `\(...\)` eingeschlossen werden (Verschachtelung ist möglich)
 - ▶ In späterem Teil des gleichen Musters kann `\m` eingesetzt werden, wobei `\m` dann für den gematchten Inhalt des `m`-ten Klammerpaars `\(...\)` steht
- Einfaches Beispiel: Eine Zeile mit zwei aufeinanderfolgenden Vorkommen von *das*

```
echo "Das hier hat nur ein das" | grep '\(das\) \1'
```



```
echo "Häufiger Vertipper: das das" | grep '\(das\) \1'
```

~~~~~

- Komplexeres Beispiel:  
Auffinden von allen entweder in einfachen (') oder doppelten (") Hochkommata geklammerten Worten
- Naiver Ansatz:  
  
`["'"].*["'"]`  
  
Schwäche: Findet z.B. auch "Hallo'
- Lösung:  
  
`\(["'"]\).*\1`  
  
Findet nur noch passende Klammerpaare
- Vorsicht mit dem Quoting in der Shell!

- Häufiger Einsatzbereich für Rückersetzung: Suchen und Ersetzen
- Beispiel: Vertauschen von Spalten in einer csv-Datei:

```
Hallo;123;  
Test;234;  
Welt;1;
```

Vertauschen der Spalten mit

```
cat test.csv | sed 's/\([a-zA-Z]*\);\([0-9]*\);/\2;\1;/'
```

Andere Möglichkeit (genereller bzgl Spalteninhalt)

```
cat test.csv | sed 's/\(.*;\)\(.*;\)/\2\1/'
```

- Alle Ausdrücke bisher Bestandteil von Basic Regular Expressions (BRE)
- Extend Regular Expressions (ERE) bieten einige nützliche Erweiterungen und sind je nach Anwendungsfall ggfs besser lesbar
- Unterscheidung zwischen BRE und ERE ist historisch gewachsen:
  - ▶ Reguläre Ausdrücke sind mathematisches Konzept aus den 1940er Jahren (als einfache Beschreibungssprache für sogenannte reguläre Mengen)
  - ▶ Erster Zusammenhang mit Computern 1968  
Paper: *Regular Expression Search Algorithm* von Ken Thompson
  - ▶ ed der erste UNIX-Editor konnte bereits reguläre Ausdrücke
  - ▶ Bezeichner `grep` kommt aus dem Befehl für Suchen und Ausgeben von `ed` (reguläre Ausdrücke Engine aus `ed` wurde aufgrund der hohen Beliebtheit als eigenes Programm `grep` umgesetzt)
  - ▶ `grep` und `egrep` waren ursprünglich zwei verschiedene Entwicklungen
  - ▶ POSIX-BRE orientieren sich am ursprünglichen Umfang von `grep`
  - ▶ POSIX-ERE orientieren sich am ursprünglichen Umfang von `egrep`

- Änderungen ERE im Vergleich zu BRE:

- ▶ `{n,m}` statt `\{n,m\}`  
dafür müssen geschweifte Klammern maskiert werden, wenn explizit danach gesucht wird
- ▶ `(...)` statt `\(...\)`  
Sonderfall: Unterstützt gemäß POSIX Gruppierung, aber keine Rückwärtsreferenz!
- ▶ Quantoren (Wiederholung, Intervallausdrücke) können sich durch Gruppierung jetzt auch auf komplette reguläre Ausdrücke oder Wortketten beziehen: z.B. `(ab)*`

- Erweiterungen:

- ▶ Quantor: `+`  
Zeichen bzw. Ausdruck darf 1 mal oder beliebig oft vorkommen - entspricht `{1,}`
- ▶ Quantor: `?`  
Zeichen bzw. Ausdruck darf 0 oder 1 Mal vorkommen - entspricht `{0,1}`
- ▶ Alternation `|`  
matcht wenn einer der Ausdrücke matcht ("Oder-Verknüpfung"), häufig in Kombination mit `()`

- Beispiele:

- ▶ *Hallo* oder *Hello*

```
echo "Hallo Hello Hullo" | grep -E 'Hallo|Hello'
      ^^^^^ ^^^^^
```

```
echo "Hallo Hello Hullo" | grep -E 'H(a|e)llo'
      ^^^^^ ^^^^^
```

- ▶ Suchen nach Zeilen, die mit *Subject* oder *To* oder *From* beginnen

```
^(Subject|To|From)
```

- ▶ Suchen nach Zeichenketten aus mindestens 2 Zahlen oder Zeichenketten aus 3 Großbuchstaben

```
echo "123 H4110 F00Bar" | grep -E '[0-9]{2,}|[A-Z]{3}'
      ^^^  ^^^^^ ^^^
```



| Zeichen | BRE/ERE | Bedeutung in einem Muster                                                                                      |
|---------|---------|----------------------------------------------------------------------------------------------------------------|
| \       | Beide   | Maskierung des folgenden Zeichens oder besondere Bedeutung aktivieren (je nach Kontext)                        |
| .       | Beide   | Beliebiges Zeichen                                                                                             |
| *       | Beide   | Beliebige Anzahl des Zeichens davor (0..). Bei ERE auch auf ()-Ausdruck anwendbar.                             |
| ^       | Beide   | Zeilenanfang                                                                                                   |
| \$      | Beide   | Zeilenende                                                                                                     |
| [...]   | Beide   | Zeichenklasse: Filterung eines bestimmten Zeichens;<br>Angabe als mögliche Zeichen oder Bereich(e)             |
| \{n,m\} | BRE     | Intervallausdruck: Zeichenhäufigkeit des Zeichens davor,<br>auch \{n\} (genau n) oder \{n,\} (mindestens n)    |
| \( \)   | BRE     | Speichert den zum Muster gefundenen Text, kann später mit Escape-Sequenz<br>\1 bis \9 wieder eingesetzt werden |
| \m      | BRE     | Verweist auf das m-te Suchmuster bzw. den dazu gemachten Text (m=1..9)                                         |
| {n,m}   | ERE     | Genau wie \{n,m\} aus BRE                                                                                      |
| +       | ERE     | Filtert eine mehrere Instanzen des Ausdrucks davor (1-n)                                                       |
| ?       | ERE     | Filtert keine oder eine Instanz des Ausdrucks davor (0-1)                                                      |
|         | ERE     | Filtert den Ausdruck, der davor oder dahinter angegeben ist                                                    |
| ( )     | ERE     | Wendet Filter auf die eingeschlossene Gruppe Ausdrücke an                                                      |

- Hinweis: Rückersetzung im Sinne von `\( \)` und `\1..\9` ist laut POSIX nicht für erweiterte reguläre Ausdrücke definiert
  - ▶ Grund: Rückbezüge sind langsam können im schlimmsten Fall exponentielle Laufzeit haben (siehe BUGS-Section in `man grep`)
  - ▶ Aber: Alle GNU Tools unterstützen die Rückersetzung auch für `( )` auch bei EREs, BSD tut das nicht (Manpages lesen!)
- Alle GNU Tools unterstützen zudem `\?`, `\+` und `\|` in BREs (analog zu `?`, `+` und `|` aus ERE)
- Nützliche Einschränkung: Wörter definieren
  - ▶ Analog zu Zeilenanfang und Zeilenende, gibt es auch Wortanfang und Wortende
  - ▶ Wortanfang: `\<`
  - ▶ Wortende: `\>`
  - ▶ Wortbildung von POSIX nur für den Editor `ed` standardisiert
  - ▶ GNU `grep` und GNU `sed` unterstützen diese Option eigentlich immer (Manpage lesen!)

- Beispiele Wortdefinition

```
echo "aaa aaab abcaaa" | grep '\<aaa'
      ^^^  ^^^
```

```
echo "aaa aaab abcaaa" | grep 'aaa\>'
      ^^^          ^^^
```

```
echo "aaa aaab abcaaa" | grep '\<aaa\>'
      ^^^
```

- GNU grep hat spezielle Option `-w` mit der es sich in den Wort-Modus versetzen lässt

```
echo "aaa aaab abcaaa" | grep -w 'aaa'
      ^^^
```

- beschreiben Klassen von speziellen Zeichen
- Hintergründe:
  - ▶ für nicht-englische Sprache reichen die einfachen Bereiche, wie a-z, manchmal nicht mehr aus, wie z.B. für die Umlaute im Deutschen
  - ▶ das Zusammenfassen von bestimmten Zeichen zu “größeren” benannten Klassen (z.B. für Whitespace, alphanumerische Zeichen) wünschenswert
- Nur innerhalb von [...] gültig
- Inhalte sind ggfs. abhängig von der eingestellten locale

## • POSIX Zeichen-Äquivalenzklassen

- ▶ beschreiben Mengen von Zeichen, die als äquivalent angesehen werden
- ▶ z.B. bei französischer locale: `[=e=]` entspricht den Zeichen e, è, é, ê

```
echo "Thérèse" | grep '[[=e=]]'
```

^ ^ ^

oder z.B. mit deutscher locale

```
echo "Hallo Hällö!" | grep 'H[[=a=]]ll[[=o=]]'
```

^ ^ ^ ^ ^ ^

## • POSIX Kollationssequenzen

- ▶ bestimmen wie besondere bzw. zusammengesetzte Zeichen z.B. bei der Sortierung und beim Matching behandelt werden (abhängig von der locale)
- ▶ z.B. `ll` im Spanischen, welches als einzelnes Zeichen behandelt wird und zwischen `l` und `m` einsortiert

```
echo "tortilla" | grep `torti[.span-ll.]a`
```

^ ^ ^ ^ ^ ^ ^ ^

- Weitere POSIX Zeichenklassen (locale-unabhängig)



| Klasse                  | Filtert Zeichen                                                               |
|-------------------------|-------------------------------------------------------------------------------|
| <code>[:alnum:]</code>  | Alphanumerische Zeichen (alphabetisch und numerisch)                          |
| <code>[:alpha:]</code>  | Alphabetische Zeichen                                                         |
| <code>[:blank:]</code>  | Leer- und Tabulatorzeichen                                                    |
| <code>[:cntrl:]</code>  | Steuerzeichen                                                                 |
| <code>[:digit:]</code>  | Ziffern                                                                       |
| <code>[:graph:]</code>  | “Schwarze” Zeichen (nicht Whitespace, nicht Steuerzeichen, etc.)              |
| <code>[:lower:]</code>  | Kleinbuchstaben                                                               |
| <code>[:print:]</code>  | Druckbare Zeichen (wie <code>[:graph:]</code> aber plus Leerzeichen)          |
| <code>[:punct:]</code>  | Interpunktionszeichen                                                         |
| <code>[:space:]</code>  | Whitespace-Zeichen (wie <code>[:blank:]</code> aber plus Zeilenumbrüche etc.) |
| <code>[:upper:]</code>  | Großbuchstaben                                                                |
| <code>[:xdigit:]</code> | Hexadezimale Ziffern                                                          |

- Beispiel

```
echo "Hallo123#" | grep '[[[:digit:]]]'  
      ^^^
```

| Operator               | Bedeutung                                                                         |
|------------------------|-----------------------------------------------------------------------------------|
| [...] [==] [::]        | Klammersymbole für Zeichenvergleiche und Zeichenketten                            |
| \metazeichen           | Geschützte Metazeichen                                                            |
| []                     | Klammerausdrücke                                                                  |
| \( \) \ziffer bzw. ()  | Unterausdrücke und Rückbezüge (BRE) bzw. Gruppierung (ERE)                        |
| * \{ \} bzw. * + ? { } | Wiederholung des vorstehenden Zeichens (BRE)<br>bzw. vorstehenden Ausdrucks (ERE) |
| <i>kein Symbol</i>     | Verkettung, z.B. ab                                                               |
| ^ \$                   | Anker                                                                             |
|                        | Alternation (nur ERE)                                                             |

Sortierung nach höchster bis niedrigster Vorrang

- Stolperfallen:

- ▶ `def*` entspricht `de(f*)` und nicht `(def)*`
- ▶ `[a-c][d-f]*` entspricht `[abc]([d-f])*` und nicht `([a-c][d-f])*`

- Positive Ganzzahlen (führende Nullen erlaubt)
  - ▶ `^[0-9][0-9]*$` (BRE/ERE)
  - ▶ `^[0-9]\{1,\}$` (nur BRE)
  - ▶ `^[0-9]+$` (nur ERE)
  - ▶ ...
- Erweiterung: Positive und negative Ganzzahlen (führende Nullen erlaubt, Plus und Minus als Präfix erlaubt)
  - ▶ `^[+-]\{0,1\}[0-9]\{1,\}$` (nur BRE)
  - ▶ `^[+-]?[0-9]+$` (nur ERE)
  - ▶ `^(+|-)?[0-9]\{1,\}$` (nur ERE)
  - ▶ ...